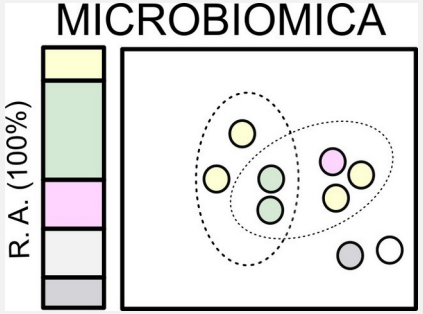
NGS et microbiome 2026 : analyse 16S rRNA reproductible du cancer du poumon avec R

Atelier pratique · PRC « Microbiote et cancer du poumon » · ISBST-UMA

13-11-2026 · ISBST, Sidi Thabet · PRC : Pr. Soumaya Kouidhi



Alif CHEBBI, PhD
Maître assistant en Microbiologie
LR11ES31 · ISBST, Université de la Manouba
alif.chebbi@isbst.uma.tn

Trois questions, trois objectifs pour cet atelier

CE QUE L'ON SE DEMANDE

- Comment passer de fichiers FASTQ à une table d'ASV ?
- Comment mesurer et comparer la diversité ?
- Que peut-on conclure, et que ne peut-on pas conclure ?

À LA FIN, VOUS SAUREZ

- Lancer et comprendre un pipeline DADA2 dans R
- Calculer et lire les diversités alpha et bêta
- Repérer 3 pièges : faible biomasse, contaminants, sélection

Astuce en or : à la fin, répondez à ces questions sans regarder vos notes.

Format Galaxy Training Network : questions et objectifs au début, points clés à la fin

Avant de commencer : un quiz de 3 minutes



alifchebbi.github.io/PRC-lung-microbiome-training/quiz/avant/

1 **Scannez le QR code**
avec l'appareil photo du téléphone

2 **Répondez aux 10 questions simples**
sans chercher : c'est votre point de départ

3 **Notez votre score**
vous referez un quiz à la fin pour mesurer vos progrès

Astuce en or : il n'y a pas de mauvaise note : ce quiz sert à voir d'où l'on part.

Trois heures dans RStudio, en deux séances

Séance 1 · 1h30
le 16S en pratique, puis la partie 1 : DADA2

→

Séance 2 · 1h30
diversité, DESeq2, interprétation

→

Exercices
en binôme, puis comparaison avec 2_Corrige

Avant de venir
`SETUP.R` doit afficher « TOUT EST PRET » · sinon : clé USB sur place ou plan B Galaxy

Deux dossiers
`1_Atelier` pour travailler · **`2_Corrige`** le même projet déjà lancé, pour comparer

Astuce en or : tout le code est déjà écrit et commenté en français : on lit, on lance, on comprend.

Le gène 16S : un code-barres bactérien

~1 500 pb

la longueur du gène

ARNr 16S, petite sous-unité du ribosome

9

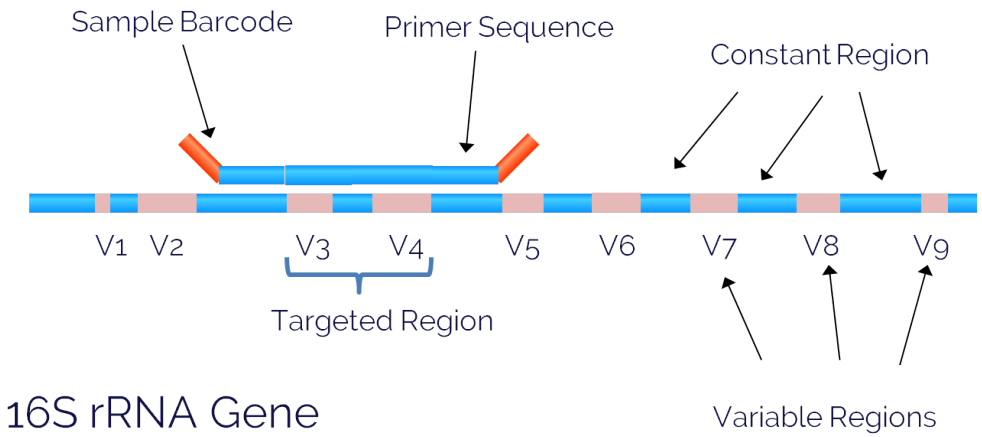
régions variables

V1 à V9, entre des régions conservées

V3-V4

notre région

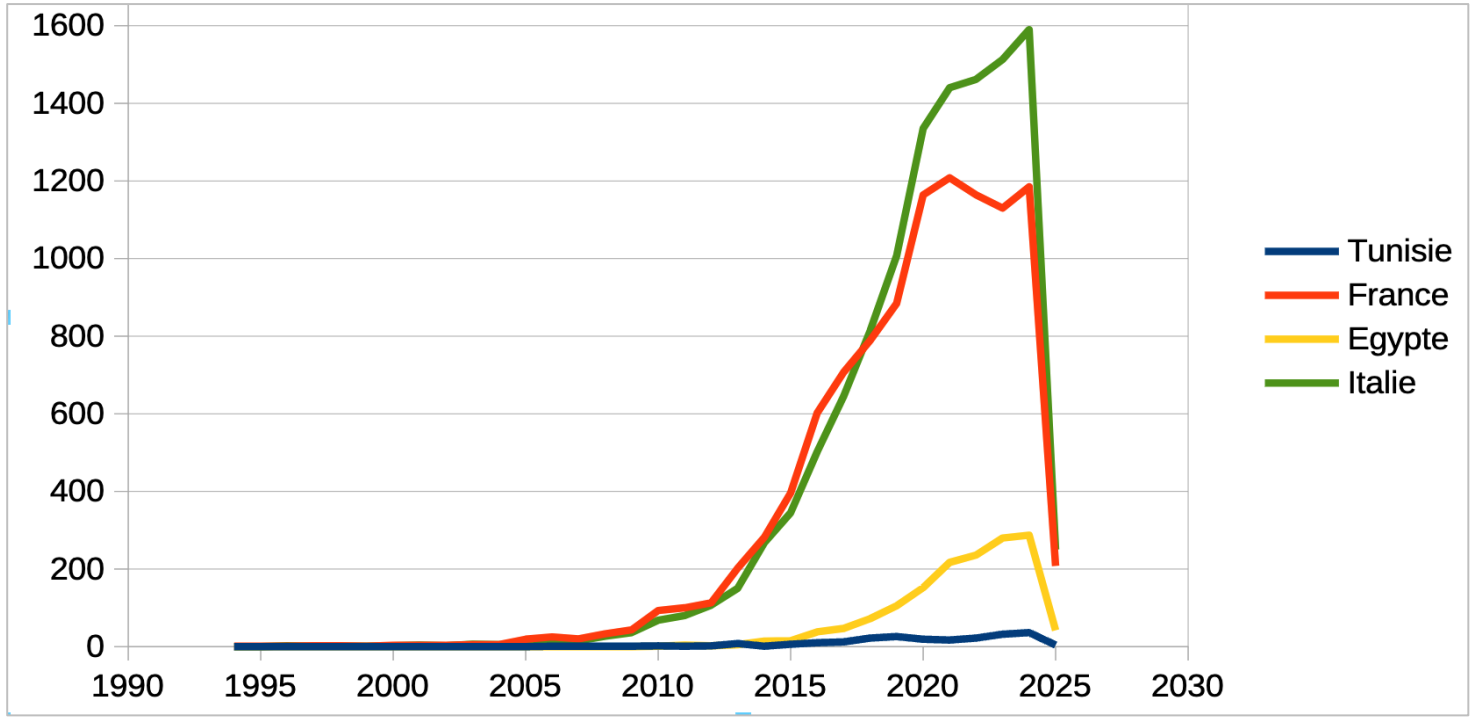
amorces 341F / 805R · amplicon ~427 pb



Astuce en or : les régions conservées portent les amorces, les régions variables donnent le nom.

Woese & Fox, PNAS 1977

En Tunisie, le microbiome passe surtout par le 16S



< 200

études par amplicons

16S, 18S, ITS en Tunisie

< 15

études shotgun

métagénomique complète

Astuce en or : le 16S est la porte d'entrée : bien le maîtriser, c'est lire la plupart des études locales.

Articles « microbiome » par pays et par année · PubMed, mars 2026 (Tunisie, France, Égypte, Italie)

Microbiome : quatre idées reçues à corriger

IDÉE REÇUE	CE QUE L'ON SAIT
« Nos bactéries pèsent 1 à 2 kg »	Moins de 500 g en tout, environ 200 g dans l'intestin
« 10 bactéries pour 1 cellule humaine »	Plutôt 1 pour 1 : le chiffre 10 venait d'une estimation de 1972
« Le domaine est né en 2011 »	Le mot « microbiome » était utilisé bien avant
« La plupart des maladies ont une dysbiose »	Lien souvent peu reproductible ; une bactérie n'est ni bonne ni mauvaise

Sender, Fuchs & Milo, PLoS Biol 2016 · présentation ISBM Monastir, avril 2026

Une étude 16S commence bien avant le séquenceur

Comparative

Maladie X vs témoins ?

notre atelier : 5 patients vs 5 témoins

Longitudinale

Comment le microbiome change-t-il ?

suivi dans le temps, avant / après traitement

Descriptive

Qui est là ?

un inventaire, sans groupe à comparer

Question → **Éthique** → **Métadonnées** → **Prélèvement** → **ADN** → **PCR 16S** → **Séquençage** → **Analyse**

Astuce en or : choisissez le plan d'étude avant le prélèvement : on ne le rattrape pas après.

Pas de microbiome sans métadonnées

PERSONNE	CLINIQUE	MODE DE VIE	ÉCHANTILLON	ENVIRONNEMENT
• sexe, âge • IMC	• maladie, stade • antibiotiques, anti-inflammatoires	• régime, tabac, alcool • activité physique	• type, site, date • conservation -80 °C	• lieu de vie • pollution

Astuce en or : notre table d'échantillons n'a ni le tabac ni l'âge : c'est une vraie limite.

Présentation ISBM Monastir, avril 2026 · Mirzayi et al., Nat Med 2021 (checklist STORMS)

Avant la PCR : six points qui font ou défont une étude

Taille
20 à 50 échantillons par groupe (ex. selles)

Conservation
congeler vite à -80 °C

Biomasse
noter la masse (g) ou la surface (cm²) prélevée

Extraction
quantité et qualité d'ADN suffisantes

Témoins négatifs
blancs d'extraction et de PCR, séquencés

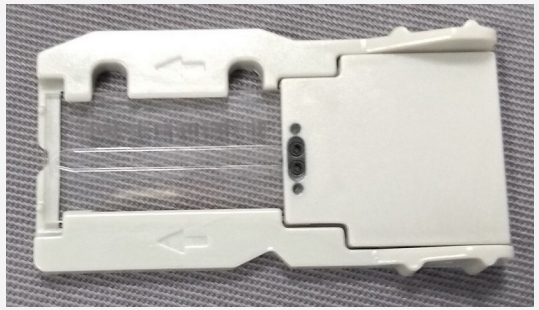
ADN de l'hôte
le retirer, surtout pour les biopsies

Astuce en or : nos biopsies bronchiques ont peu d'ADN bactérien : les témoins négatifs y sont indispensables.

Présentation ISBM Monastir, avril 2026 · Eisenhofer et al., Trends Microbiol 2019

Illumina ou Nanopore : deux façons de lire l'ADN

ILLUMINA (MISEQ) · NOTRE ATELIER



- On ajoute une base colorée à la fois ; une caméra la photographie
- *Comme photographier chaque lettre écrite, pour des millions de phrases*

flow cell MiSeq : une lame de verre

2 x 300 bases · ~1 erreur sur 1 000 · 16S : une région (V3-V4)

NANOPORE (MINION)



- Le brin d'ADN passe dans un trou ; chaque base change le courant
- *Comme un collier de perles qu'on sent passer dans un trou*

flow cell MinION : une puce à nanopores

16S entier (~1 500 bases) · en temps réel · souvent jusqu'à l'espèce

Astuce en or : Illumina pour la précision et le nombre d'échantillons ; Nanopore pour la longueur et la rapidité.

Bentley et al., Nature 2008 · Jain et al., Genome Biol 2016 · Curry et al., Nat Methods 2022 · photos : Ciro Santilli, Wikimedia Commons, CC BY-SA 4.0

Ce qui se passe dans la flow cell

ILLUMINA : LECTURE PAR LA COULEUR



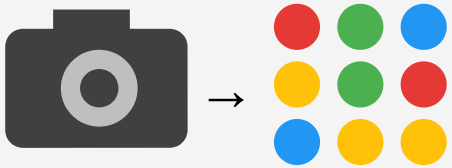
1 · L'ADN se fixe sur la lame de verre



2 · Copiée en grappes (clusters)

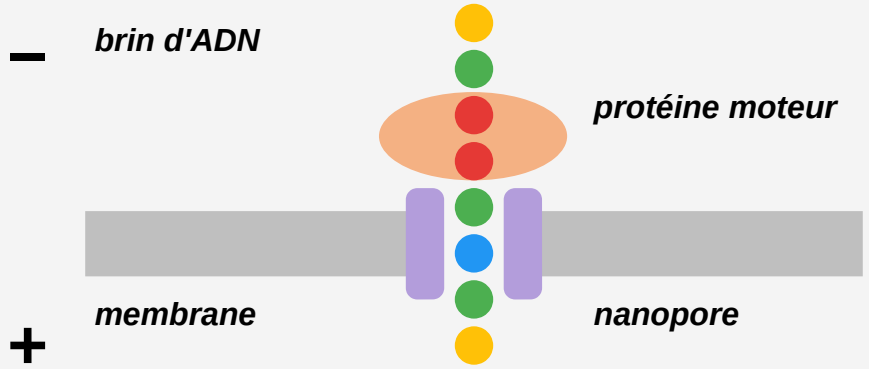


3 · Une base colorée s'ajoute à chaque cycle

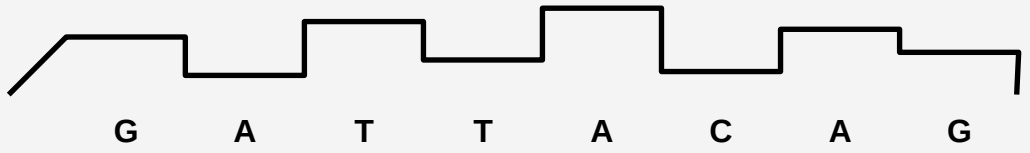


4 · Photo de chaque grappe → T, A, C, G...

NANOPORE : LECTURE PAR LE COURANT



Chaque base change le courant → basecalling



Astuce en or : Illumina photographie des couleurs ; Nanopore écoute un courant électrique.

Bentley et al., Nature 2008 (séquençage par synthèse) · Jain et al., Genome Biol 2016 (MinION) · schéma simplifié

Le séquenceur remplit un réservoir de lectures

	Éch. 1	Éch. 2	Éch. 3
ASV 1	1 000	20	500
ASV 2	0	20	200
ASV 3	2 000	1 000	4 000
Total	3 000	1 040	4 700

Les totaux dépendent du séquençage, pas de la biologie.

Deux réponses

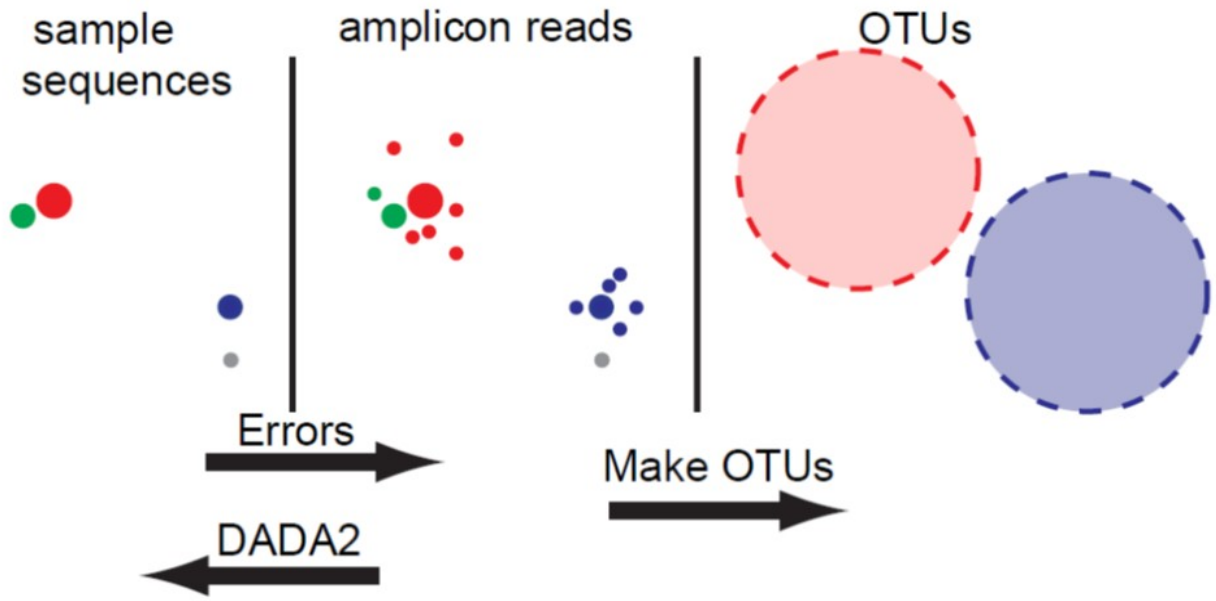
Proportions ou raréfaction

On compare des pourcentages, ou l'on tire au hasard le même nombre de lectures par échantillon (ici, 1 000) : c'est la raréfaction.

Astuce en or : ce sont des proportions : pour des quantités absolues, il faut la qPCR ou la culture.

Lozupone et al., ISME J 2011 · Gloor et al., Front Microbiol 2017

OTU ou ASV : regrouper à 97 % ou corriger les erreurs



OTU
on regroupe les séquences à 97 % d'identité · mothur, QIIME 1

ASV
DADA2 corrige les erreurs : séquences exactes, comparables entre études

Outils : DADA2 (notre atelier), QIIME 2 (à ne pas appeler « KIIME »), mothur, nf-core/ampliseq

Astuce en or : un ASV est une séquence exacte : on peut le retrouver d'une étude à l'autre.

Callahan, McMurdie & Holmes, ISME J 2017

OTU, ASV, zOTU : deux idées, plusieurs noms

Unité	Comment on l'obtient	Outil	Résolution	Comparable entre études ?
OTU (97 %)	on regroupe les séquences à 97 %	VSEARCH, mothur, QIIME 1	~ genre	non
ASV / ESV	on corrige les erreurs : séquence exacte	DADA2 (notre atelier)	1 nucléotide	oui
zOTU	« OTU de rayon zéro » : débruitage	USEARCH (UNOISE3)	1 nucléotide	oui
sOTU	« sub-OTU » : débruitage	Deblur (QIIME 2)	1 nucléotide	oui
Oligotype / MED	positions qui varient le plus	oligotyping, MED	quelques nucléotides	en partie
Phylotype	on regroupe par nom de taxon	mothur + SILVA	genre	oui, par le nom

Astuce en or : ASV, ESV, zOTU et sOTU : quatre noms pour la même idée, la séquence exacte corrigée.

Callahan et al., ISME J 2017 · Edgar, bioRxiv 2016 (UNOISE) · Amir et al., mSystems 2017 (Deblur) · Eren et al., ISME J 2015 (MED)

La base de référence et sa version comptent

Ancien nom (SILVA 138.1)	Nom valide (2021)
Firmicutes	**Bacillota**
Proteobacteria	**Pseudomonadota**
Bacteroidetes	**Bacteroidota**
Actinobacteria	**Actinomycetota**

Bases courantes

SILVA, GTDB, RDP

Nos figures utilisent SILVA 138.1 : elles écrivent encore « Firmicutes ».

« If you don't know the names of things, the knowledge of them is lost too. » Linné, 1751

Astuce en or : notez toujours la base et sa version dans vos méthodes : SILVA 138.1 ici.

Oren & Garrity, Int J Syst Evol Microbiol 2021

PRJNA586753

Notre jeu de données : biopsies de Saragosse

5

patients
biopsie de la bronche atteinte

5

témoins sans cancer
biopsie bronchique

5 000

paires de lectures
par échantillon · MiSeq 2 x 300

Le point fort
même tissu, et de vrais témoins sans cancer

Attention
les 10 biopsies qui séparent le mieux les groupes

Noms des fichiers
`TU01_R1.fastq.gz` = patient TU01, lecture R1 · HC = témoin

Astuce en or : notez toujours comment les échantillons ont été choisis : ici, c'est pédagogique.

Bello et al., Arch Bronconeumol 2021 · NCBI BioProject PRJNA586753

Ouvrir le projet et lancer le code

1 **Double-cliquer sur le .Rproj**
`Atelier_16S_cancer_poumon.Rproj`

2 **Vérifier le dossier de travail**
`getwd()` doit finir par 1_Atelier

3 **Sinon : menu Session**
ou `setwd("chemin/vers/1_Atelier")`

Lancer...	Raccourci
une ligne	Ctrl + Entrée
une case	Ctrl + Maj + Entrée
tout	Ctrl + Alt + R
le rapport	Ctrl + Maj + K

Astuce en or : lancez les cases une par une, de haut en bas, et lisez chaque résultat.

Détails dans 1_Atelier/GUIDE_DEBUTANT.md · sur Mac : Cmd au lieu de Ctrl, Option au lieu de Alt

DADA2 en une histoire : les fautes de frappe

Toute une classe recopie une liste de villes. Certains élèves font des fautes. DADA2 doit retrouver la vraie liste.

Mot copié	Copies	DADA2 décide
Tunis	980	**vrai mot**
Tumis	15	**faute → Tunis**
Sousse	400	**vrai mot**

1 · Nettoyer
jeter les copies tachées (mauvaise qualité)

2 · Apprendre les fautes
quelles lettres chaque élève confond souvent

3 · Décider
« Tumis » est rare et à 1 lettre de « Tunis » : c'est une faute

4 · Garder les vrais mots
chaque vrai mot = un ASV, compté dans chaque échantillon

Astuce en or : un ASV = un « vrai mot » : une séquence exacte, sans les fautes du séquenceur.

Callahan et al., Nat Methods 2016

Le chemin des données : huit étapes DADA2

1 · Qualité
`plotQualityProfile`
regarder les copies

2 · Filtrage
`filterAndTrim`
jeter les copies tachées

3 · Erreurs
`learnErrors`
apprendre les fautes habituelles

4 · Débruitage
`dada`
Tumis → Tunis

5 · Fusion R1+R2
`mergePairs`
recoller le billet déchiré

6 · Longueur
`nchar 400-432`
jeter ce qui est hors sujet

7 · Chimères
`removeBimeraDenovo`
jeter les photomontages

8 · Taxonomie
`assignTaxonomy`
donner la carte d'identité

Astuce en or : suivez le nombre de lectures après chaque étape : une chute brutale montre le problème.

Callahan et al., Nat Methods 2016 · partie 1 : 01_upstream_DADA2.Rmd

Leçon 1 : vérifier avant de faire confiance

Ce que l'on voit

Les amorces sont encore là : R1 commence par `CCTACGG...`

L'analogie

l'emballage d'un cadeau : on l'enlève avant de regarder dedans

1 **Retirer les amorces**

`trimLeft = c(17, 21)`

2 **Couper où la qualité baisse**

`truncLen = c(280, 220)`

3 **Garder le chevauchement**

263 + 199 = 462 pb pour ~427

Astuce en or : regardez toujours vos données brutes avant de lancer un pipeline.

Leçon 2 : très peu d'ADN bactérien

27-41 %

des R1 avec l'amorce

chez 4 témoins sur 5 (63-88 % chez les patients)

628 → 399

ASV gardés

le reste : surtout de l'ADN humain

8-15 %

lectures finales

chez 3 témoins (36-49 % chez les patients)

Peu de bactéries
faible biomasse

→

Beaucoup de bruit
ADN humain, réactifs

→

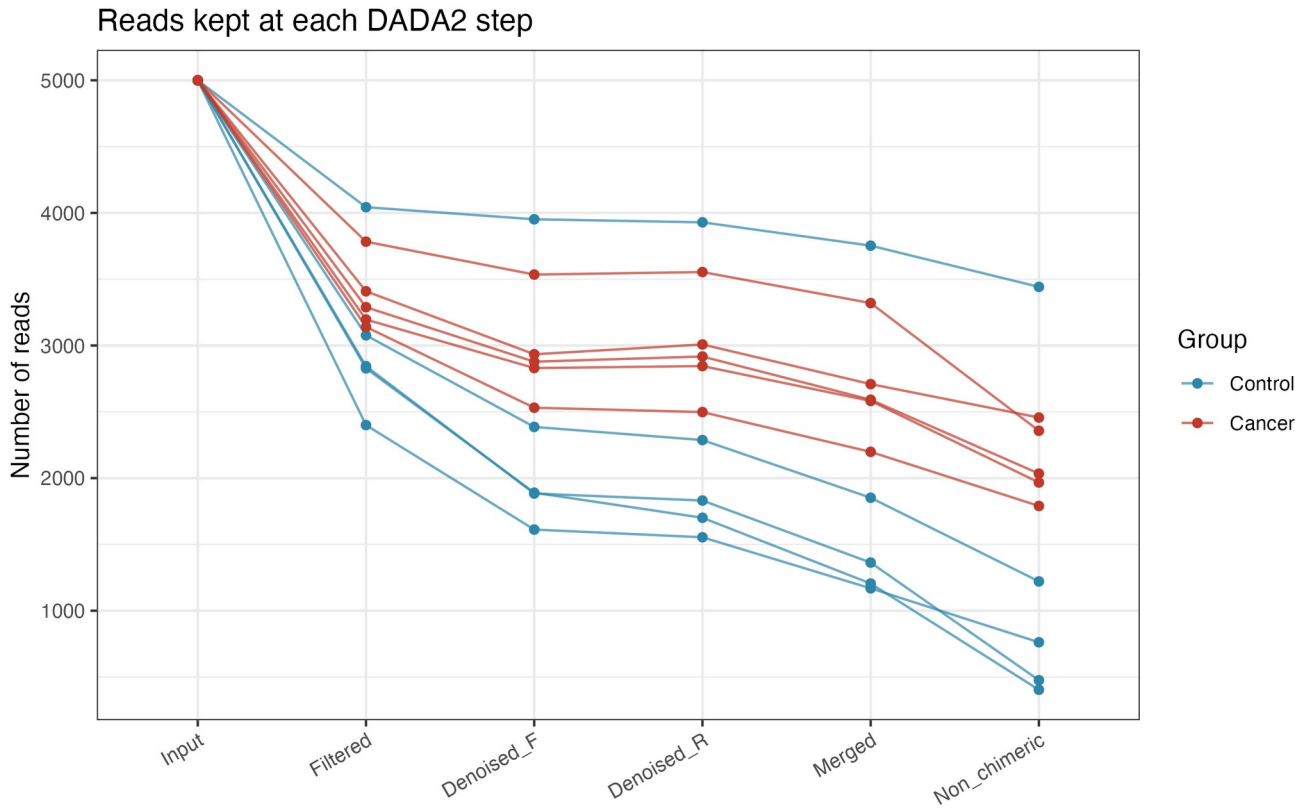
Contaminants
pèsent plus lourd

Astuce en or : séquencez des blancs d'extraction pour pouvoir retirer les contaminants (decontam).

Salter et al., BMC Biol 2014

PRJNA586753

Combien de lectures restent à chaque étape ?



16 910

lectures à la fin

sur 50 000 paires au départ (34 %)

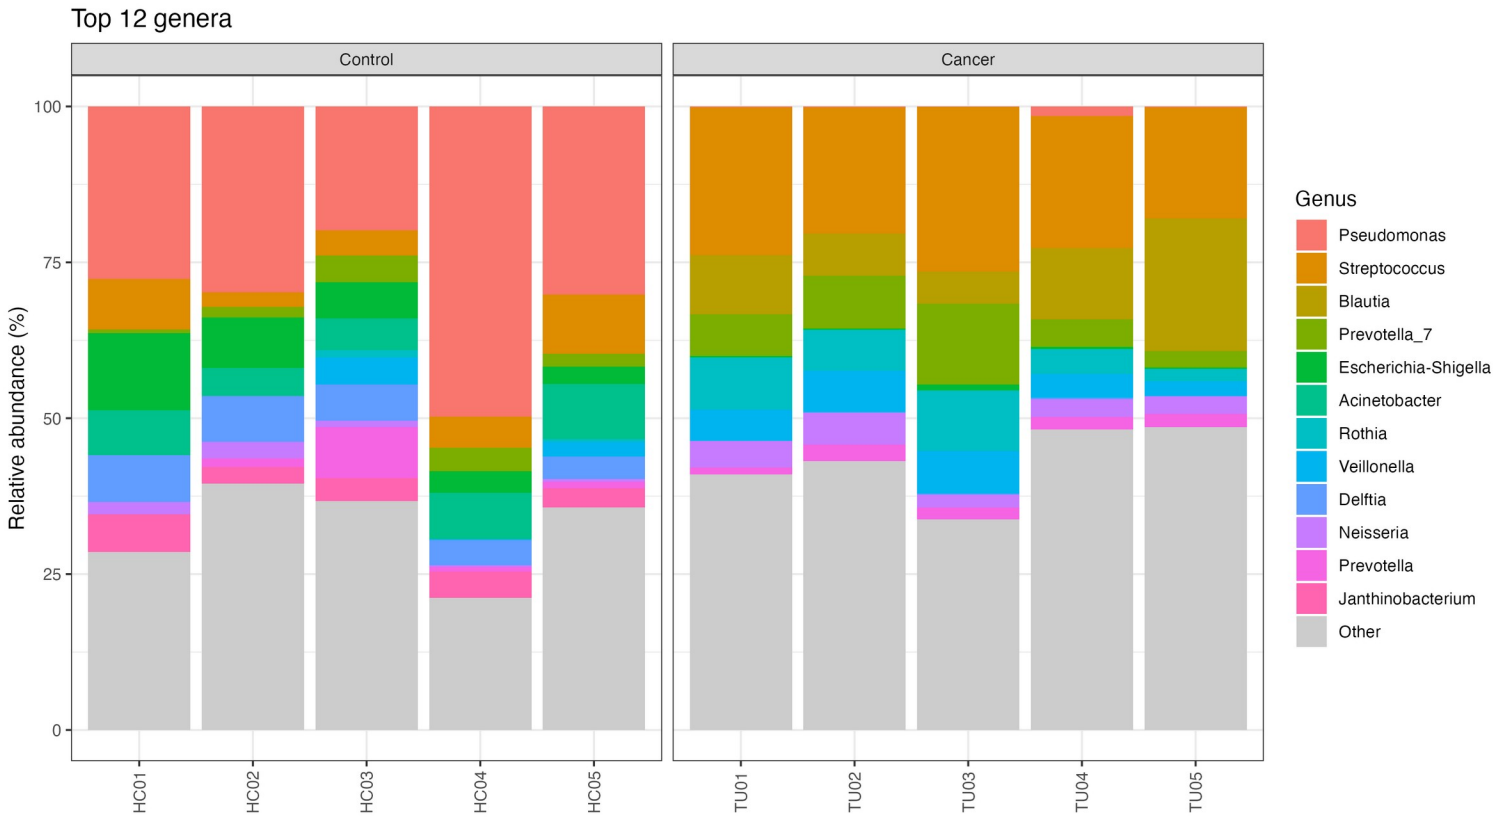
379

ASV

après suppression des chimères

Astuce en or : comme les passagers d'un bus : les témoins (bleu) descendent les premiers.

Qui est là ? Pas les mêmes genres



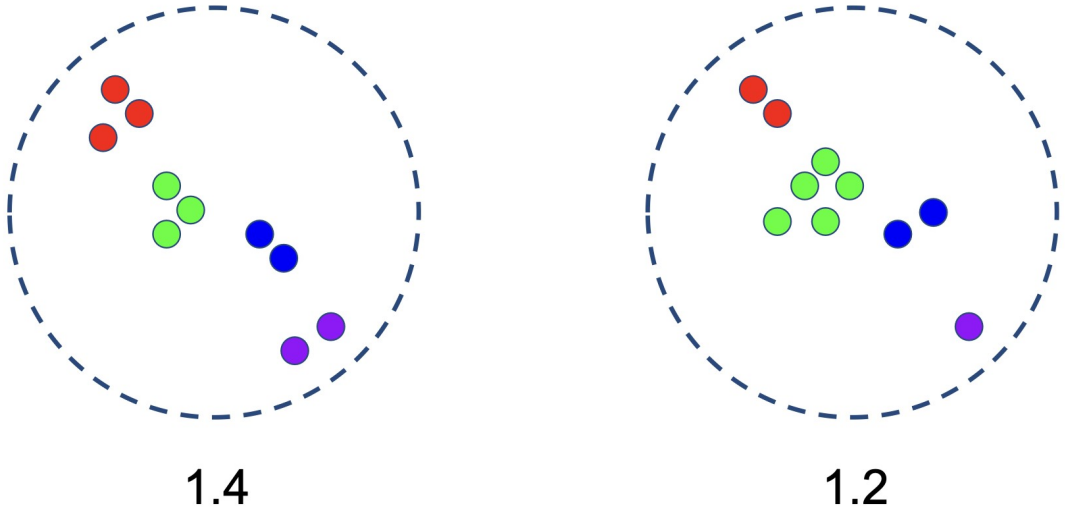
Abondance relative
en % de chaque échantillon

Témoins
Pseudomonas 31 %

Patients
Streptococcus 22 %, *Blautia* 11 %

Astuce en or : à faible biomasse, les genres dominants viennent souvent des réactifs.

Quelle est votre question de biodiversité ?



Mêmes 4 espèces · à gauche 2-3-2-2, à droite 2-5-2-1 · Shannon 1,4 et 1,2

Richesse
combien d'espèces ? ici 4 et 4

Équitabilité
sont-elles en quantités égales ? gauche oui

Dominance
une espèce prend-elle la place ? droite : les vertes

Astuce en or : alpha = la diversité dans un échantillon ; bêta = la différence entre échantillons.

Indices alpha : trois façons de compter un jardin

Indice	Question	Exemple de la vie courante	Jardin A	Jardin B
Observed	combien d'espèces ?	compter les espèces, pas les pieds	4	4
Shannon	richesse + équilibre	une classe où tout le monde parle	1,39	0,59
Simpson	2 tirages = 2 espèces ?	tirer 2 billes d'un sac	0,75	0,27
Pielou	équilibre seul (0 à 1)	1 = tout en même quantité	1,00	0,42

Jardin A : 25-25-25-25 (équilibré) · Jardin B : 85-5-5-5 (une espèce domine) · 100 plantes, 4 espèces

Astuce en or : Shannon voit les espèces rares, Simpson les dominantes : regardez les deux.

Shannon : $H = -\Sigma\, p \cdot \ln p$ · Simpson : $1 - \Sigma\, p^2$ · Pielou : $H / \ln S$ · calculs dans la partie 2, étape 5

Bêta : deux boîtes à goûter se ressemblent-elles ?

Boîte d'Amira
5 pommes · 3 bananes · 2 dattes

Boîte de Sami
1 pomme · 1 banane · 8 oranges

Alpha
dans une boîte : 3 et 3 sortes

Bêta
entre deux boîtes

Gamma
en tout : 4 sortes

0,50

Jaccard : qui est là ?
2 fruits en commun sur 4 sortes · listes de courses

0,33

Sørensen : qui est là ?
les fruits communs comptent deux fois

0,80

Bray-Curtis : qui et combien ?
seulement 2 fruits sur 20 en commun

Astuce en or : mêmes boîtes, distances différentes : le choix de la distance change la réponse.

0 = boîtes identiques · 1 = rien en commun · Whittaker, Ecol Monogr 1960 (alpha, bêta, gamma)

Quatre familles de distances bêta

Famille	Elle regarde...	Distances	Pour les étudiants
Présence / absence	qui est là	**Jaccard, Sørensen**	deux listes de courses
Abondance	qui et combien	**Bray-Curtis**	compter les fruits de deux paniers
Phylogénie	qui, combien et la famille	**UniFrac (pondéré ou non)**	la pomme et la poire sont cousines
Proportions	les rapports entre bactéries	**Aitchison (CLR)**	comparer deux recettes

Piège du double zéro
sans kiwi tous les deux ≠ boîtes semblables

Remplacer ou emboîter
dattes contre oranges, ou une boîte = morceau de l'autre

Astuce en or : dans l'atelier, Bray-Curtis ; Jaccard est calculé sur les jardins A et B.

Lozupone & Knight, Appl Environ Microbiol 2005 (UniFrac) · Gloor et al., Front Microbiol 2017 (Aitchison) · Baselga, Glob Ecol Biogeogr 2010

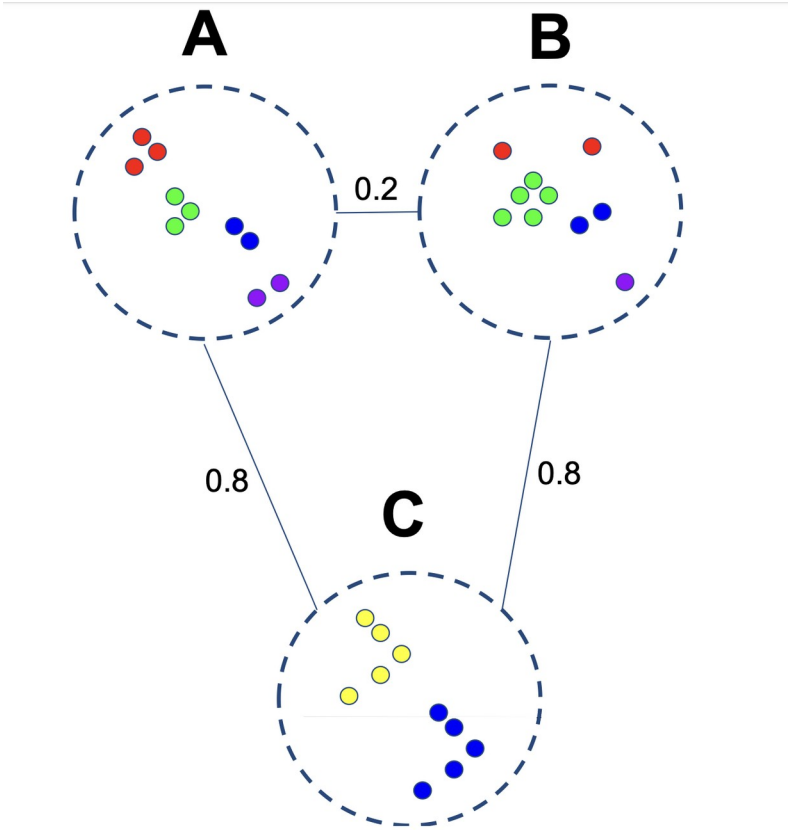
Quelle distance pour quelle question ?

Jaccard, Sørensen	**Qui est présent ou absent ?** un pathogène, un taxon rare ou un contaminant apparaît-il dans un groupe ?
Bray-Curtis	**Les bactéries dominantes changent-elles de quantité ?** patients vs témoins (notre atelier), avant / après antibiotiques
UniFrac non pondéré / pondéré	**Des lignées entières sont-elles gagnées ou perdues ?** non pondéré : sol vs intestin · pondéré : grands groupes qui montent ou baissent
Aitchison (CLR)	**Les rapports entre bactéries changent-ils ?** statistiques rigoureuses, apprentissage automatique, sans raréfaction

Astuce en or : calculez deux distances (présence et abondance) : si elles divergent, c'est une information.

Lozupone et al., Appl Environ Microbiol 2007 · Gloor et al., Front Microbiol 2017

Bêta : A, B et C se ressemblent-ils ?



Bray-Curtis (abondances)
0 = même composition · 1 = rien en commun

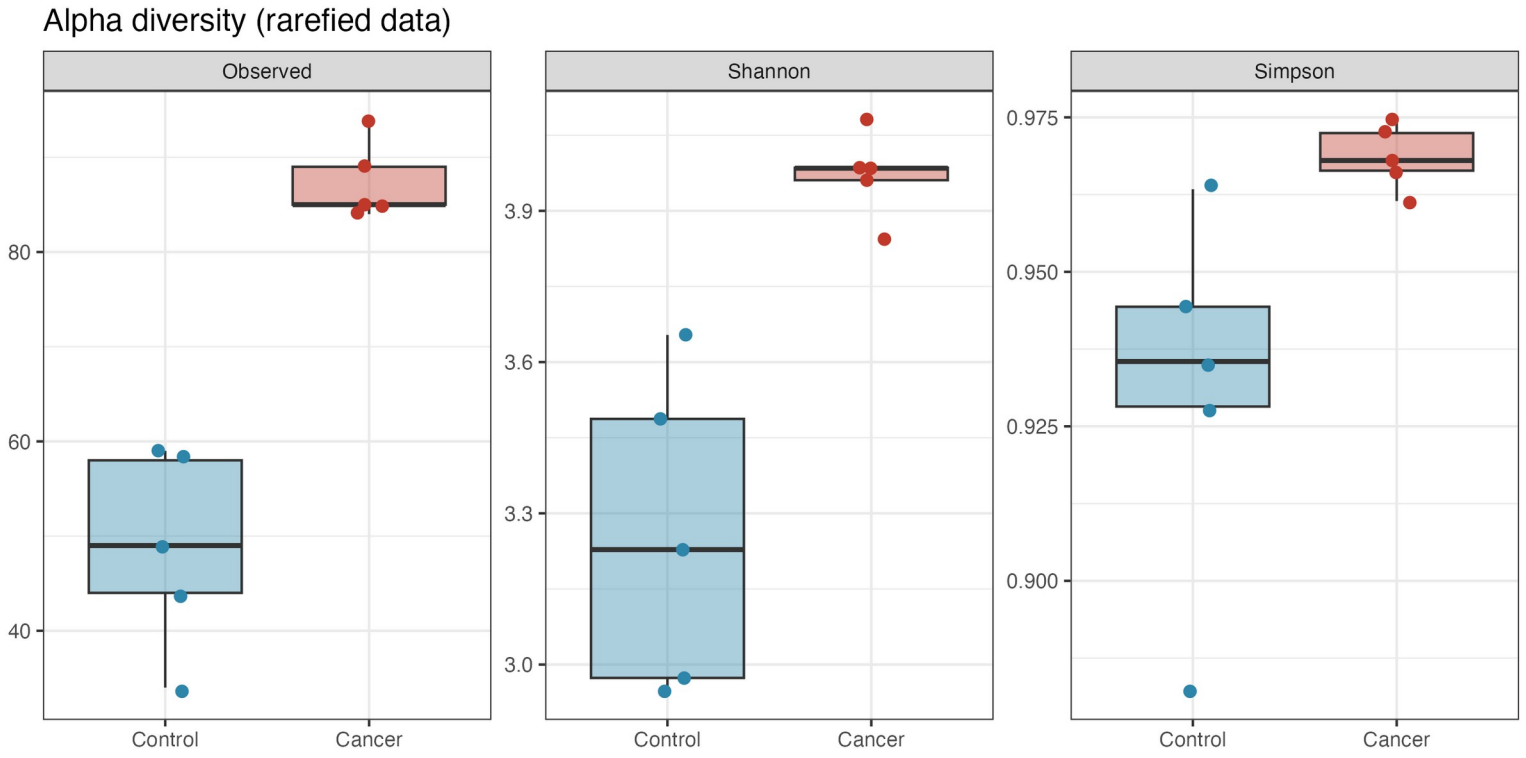
A et B = 0,2
mêmes couleurs, quantités proches : très semblables

A et C = 0,8
presque rien en commun : très différents

Astuce en or : Bray-Curtis compare deux paniers en comptant les fruits ; Jaccard compare seulement les listes de courses.

Présentation ISBM Monastir, avril 2026 · jardins A et B : Bray-Curtis 0,60, Jaccard 0 (partie 2, étape 6)

Alpha : les patients sont plus divers



p = 0,012

Shannon

Wilcoxon-Mann-Whitney

Raréfaction

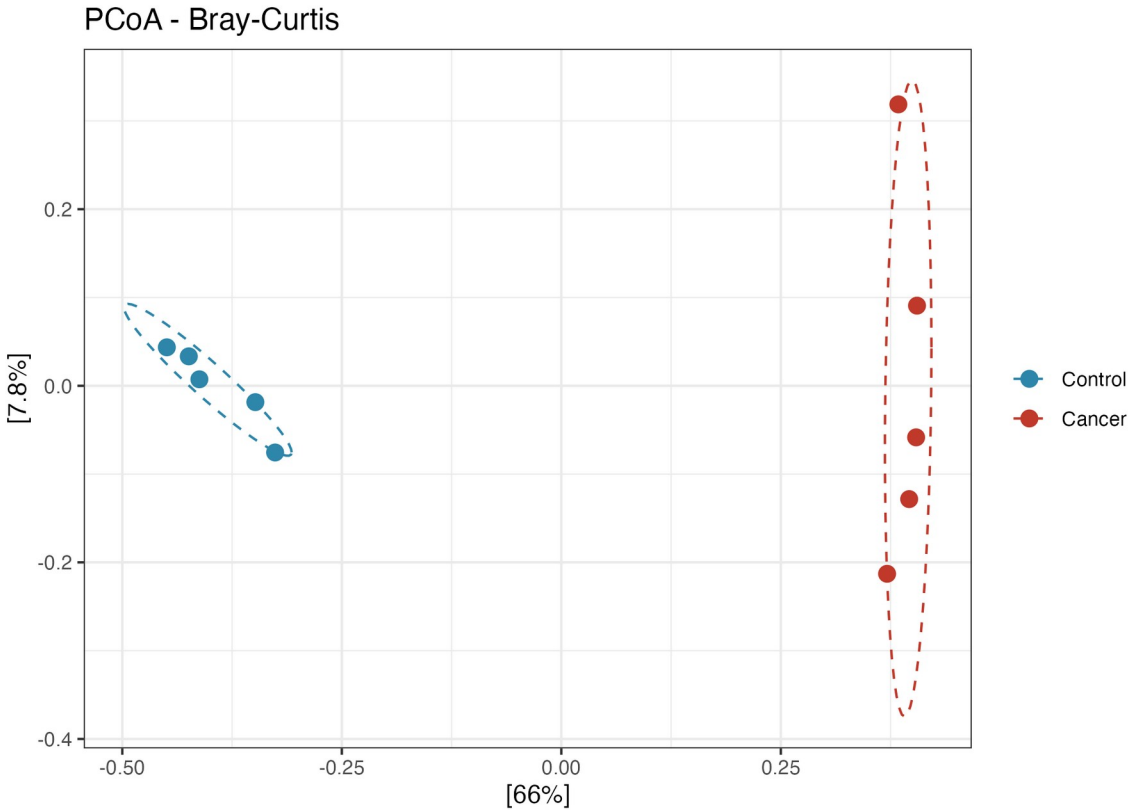
347 lectures par échantillon

Piège

échantillons choisis

Astuce en or : raréfier jette des lectures : vérifiez la profondeur minimale.

Bêta : les deux groupes se séparent



$R^2 = 0,66$

PERMANOVA (p = 0,01)

le groupe explique 66 % des différences

betadisper : p = 0,33

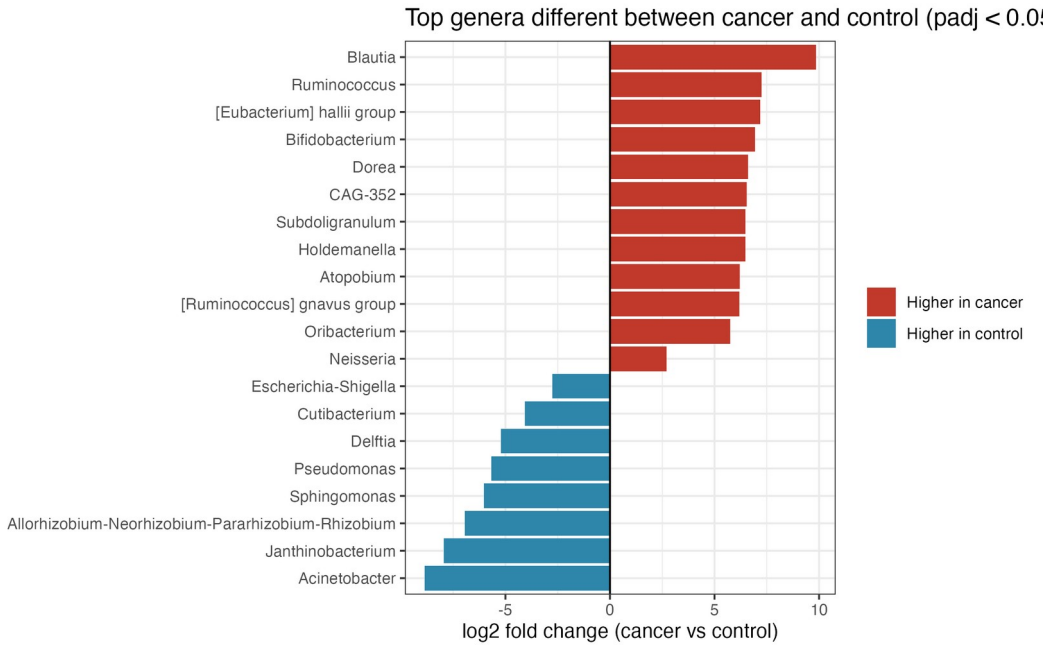
étalement comparable entre groupes

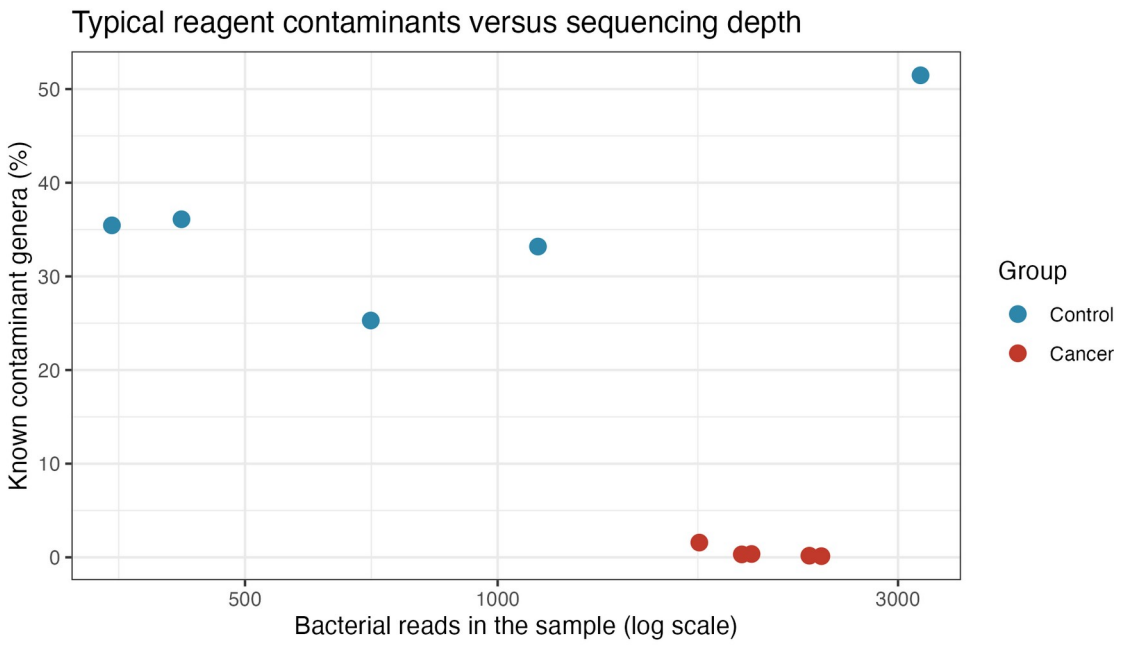
NMDS : stress ≈ 0

carte dégénérée : on garde la PCoA

Astuce en or : $R^2 = 0,66$ est énorme en microbiome : trop beau, cherchez pourquoi.

Quelles bactéries diffèrent ? Prudence





55 genres sur 75
padj < 0,05 : signal rouge

Kitome
rho = -0,42 avec la profondeur

Une pincée de sel
invisible dans la marmite, forte dans une tasse

Astuce en or : avant de croire un genre : un seul échantillon ? un contaminant connu ?

Love et al., Genome Biol 2014 · Davis et al., Microbiome 2018

Ce que l'on peut dire, ou pas encore

NOUS POUVONS DIRE	NOUS NE POUVONS PAS ENCORE DIRE
Les profils diffèrent dans ces 10 biopsies	Que ces bactéries causent le cancer
Les témoins sont riches en genres de réactifs	Qu'il s'agit d'un biomarqueur (5 par groupe)
Les patients ont des genres de la bouche	Ce que font les bactéries (16S ≠ fonction)
La méthode, étape par étape	Que le résultat tient sans témoins négatifs

Autres confusions possibles : tabac, âge, sexe, BPCO, bactéries orales apportées par le bronchoscope

Limites du 16S et bonnes pratiques

LIMITES

- Proportions : risque de faux positifs
- Genre, rarement espèce
- Pas de fonction
- Biais des amorces et de la PCR

BONNES PRATIQUES

- qPCR ou culture pour confirmer
- Checklist STORMS, plan déclaré à l'avance
- Comparer deux outils, documenter chaque choix
- Pas de « pêche » dans les données

Mirzayi et al., Nat Med 2021 · présentation ISBM Monastir, avril 2026

À vous de jouer : quatre exercices en binôme

1 **Couper R2 plus court**
`trunc_reverse <- 180` : la fusion marche-t-elle ?

2 **Sans filtre de longueur**
étape 10 : combien d'ASV en plus ? de quoi s'agit-il ?

3 **Niveau phylum**
DESeq2 avec `taxrank = "Phylum"`

4 **Un témoin en moins**
sans HC04 : le R^2 reste-t-il stable ?

Astuce en or : notez chaque réglage changé et son effet, puis comparez avec 2_Corrige.

Trois choses à retenir

1 **Regarder les données brutes avant tout réglage**
qualité, amorces, longueur, nombre de lectures à chaque étape

2 **Choisir l'indice selon la question**
richesse, équilibre ou dominance · Bray-Curtis ou Jaccard

3 **Se méfier d'un signal trop beau**
sélection des échantillons, faible biomasse, kitome

Un bon résultat de microbiome est un résultat que l'on a essayé de casser.

Plan B : DADA2 dans le navigateur, sans installation

1 **Créer un compte**
sur usegalaxy.eu

2 **Suivre le tutoriel GTN**
« Building an ASV table from 16S data using DADA2 »

3 **Lancer les outils DADA2**
filterAndTrim → learnErrors → dada → mergePairs

Tutoriel Galaxy (GTN)

Astuce en or : utilisez les données du tutoriel (souris, V4) : plus courtes et testées dans Galaxy.

Tout le matériel, en accès libre



README
installation en 4 étapes + tutoriels recommandés

SETUP.R ou le package atelier16S
installe tout · « TOUT EST PRET »

1_Atelier + 2_Corrige
on travaille dans l'un, on compare avec l'autre

Releases
un ZIP par ordinateur + les FASTQ seuls

Astuce en or : changez les FASTQ et les métadonnées, gardez les scripts.

github.com/alifchebbi/PRC-lung-microbiome-training · R 4.5.2 · Bioconductor 3.22 · DADA2 · phyloseq · vegan · DESeq2 · SILVA 138.1

Après l'atelier : refaites le quiz



`alifchebbi.github.io/PRC-lung-microbiome-training/quiz/apres/`

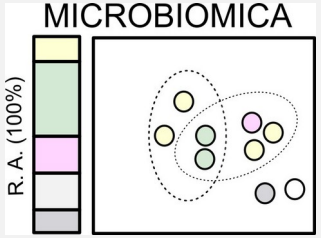
1 **Scannez le QR code**
aujourd'hui ou plus tard, chez vous

2 **Répondez aux 20 questions**
une explication s'affiche après chaque réponse

3 **Comparez vos deux scores**
avant (sur 10) et après (sur 20) : mesurez vos progrès

Astuce en or : une question ratée ? relisez sa diapositive et le rapport HTML de 2_Corrige.

LBVBGR-LR11ES31



Merci

Du FASTQ à l'interprétation : apprendre à douter de ses données

Questions bienvenues

alif.chebbi@isbst.uma.tn

Instagram : Microbiomica_chebbi

Merci à Pr. Soumaya Kouidhi et à Houcemeddine Othman